Анализ данных и проверка гипотез о чаевых в ресторане

Стек: Python • Pandas • Matplotlib • Seaborn • Plotly



Квасова-Изотова
Анна Владимировна

2026

Импорт библиотек и загрузка датасета

Что сделано:

1. Импортированы необходимые библиотеки
2. Загружен датасет `tips`
3. Выведены первые строки
4. Проверена общая информация о датасете

```python
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import plotly.express as px

```

```python
tips = sns.load_dataset('tips')

tips.head()

tips.info()

print()
print('Описание переменных:')
print('1. total_bill – общая сумма счёта (без чаевых)')
print('2. tip – размер чаевых')
print('3. sex – пол клиента')
print('4. smoker – курит ли клиент')
print('5. day – день недели')
print('6. time – время посещения (обед или ужин)')
print('7. size – размер компании (количество человек)')

```

Результат

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 244 entries, 0 to 243
Data columns (total 7 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   total_bill  244 non-null    float64
 1   tip         244 non-null    float64
 2   sex         244 non-null    category
 3   smoker      244 non-null    category
 4   day         244 non-null    category
 5   time        244 non-null    category
 6   size        244 non-null    int64
dtypes: category(4), float64(2), int64(1)
memory usage: 7.4 KB

Описание переменных:
1. total_bill – общая сумма счёта (без чаевых)
2. tip – размер чаевых
3. sex – пол клиента
4. smoker – курит ли клиент
5. day – день недели
6. time – время посещения (обед или ужин)
7. size – размер компании (количество человек)
```

244
наблюдения

7
признаков

Типы данных

- 4 категориальных (category)
- 2 числовых (float64)
- 1 целочисленный (int64)

Вывод

Данные загружены и изучены. Датасет содержит числовые и категориальные переменные, необходимые для дальнейшего анализа факторов, связанных с размером чаевых.

Проверка данных перед анализом

Что сделано:

1. Проверены пропуски в данных
2. Проверены полные дубликаты строк
3. Проверены уникальные значения категорий
4. Посчитано количество чеков по дням и времени

```
display(pd.DataFrame({'Пропуски': tips.isna().sum()}))

display(tips.duplicated().sum())

print()
print('Строки-дубликаты:')
display(tips[tips.duplicated(keep=False)])

print()
print('Уникальные значения:')
print('Пол:')
display(tips['sex'].unique())
print()
print('Статус курения:')
display(tips['smoker'].unique())
print()


print('День:')
display(tips['day'].unique())


print()
print('Время:')
display(tips['time'].unique())

print()
display(pd.DataFrame({'Число чеков по дням': tips['day'].value_counts(dropna=False)}))
display(pd.DataFrame({'Число чеков по времени': tips['time'].value_counts(dropna=False)}))

```

Результат

	Пропуски
total_bill	0
tip	0
sex	0
smoker	0
day	0
time	0
size	0

np.int64(1)

Число чеков по дням

day	
Sat	87
Sun	76
Thur	62
Fri	19

Число чеков по времени

time	
Dinner	176
Lunch	68

Строки-дубликаты:

	total_bill	tip	sex	smoker	day	time	size
198	13.0	2.0	Female	Yes	Thur	Lunch	2
202	13.0	2.0	Female	Yes	Thur	Lunch	2

```
Уникальные значения:
Пол:
['Female', 'Male']
Categories (2, object): ['Male', 'Female']

Курит:
['No', 'Yes']
Categories (2, object): ['Yes', 'No']

День:
['Sun', 'Sat', 'Thur', 'Fri']
Categories (4, object): ['Thur', 'Fri', 'Sat', 'Sun']

Время:
['Dinner', 'Lunch']
Categories (2, object): ['Lunch', 'Dinner']
```

0
пропусков

1
пара дубликатов

4
дня недели

176
чеков на ужин

Вывод

Датасет пригоден к анализу: пропусков нет, категориальные признаки не содержат опечаток. Найденный дубликат (198 и 202) обоснованно оставлен, так как в ресторанном бизнесе два одинаковых чека за один обед — это нормальная ситуация. Данные готовы к дальнейшей проверке гипотез.

Гипотеза 1: чем больше счет, тем больше чаевые

Что сделано:

1. Scatter plot
2. Линия регрессии
3. Расчёт корреляции Пирсона и Спирмена
4. Поиск исключений

```python
sns.regplot(data=tips, x="total_bill", y="tip")

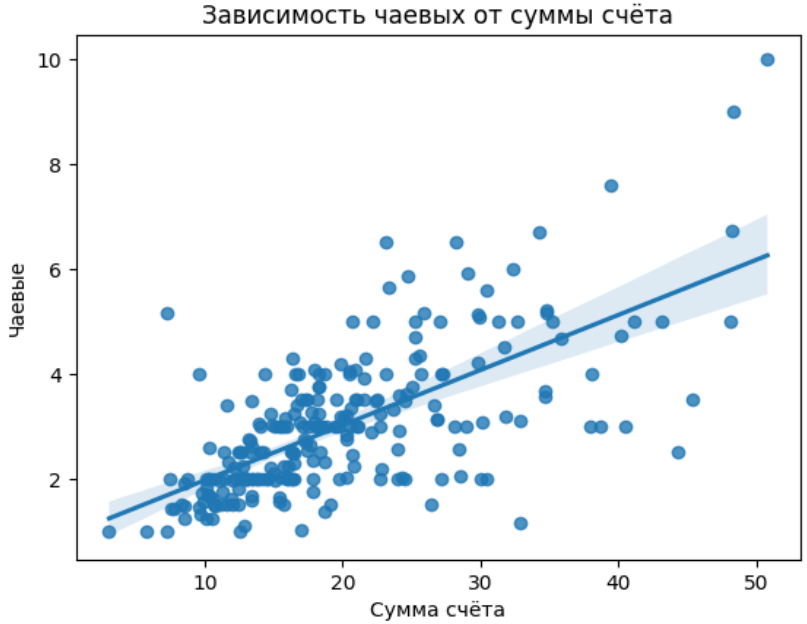
plt.title("Зависимость чаевых от суммы счёта")
plt.xlabel("Сумма счёта")
plt.ylabel("Чаевые")
plt.show()

print('Корреляция:')
pearson_r = tips['total_bill'].corr(tips['tip'], method='pearson').round(2)
spearman_r = tips['total_bill'].corr(tips['tip'], method='spearman').round(2)
print('Пирсон:', pearson_r)
print('Спирмен:', spearman_r)

print()
tips[['total_bill', 'tip']].describe().round(2)
tips[(tips['total_bill'] > 24) & (tips['tip'] < 2)]

```

Результат



Корреляция:
Пирсон: 0.68
Спирмен: 0.68

	total_bill	tip	sex	smoker	day	time	size
57	26.41	1.50	Female	No	Sat	Dinner	2
237	32.83	1.17	Male	Yes	Sat	Dinner	2

0.68
корреляция

2
исключения

Вывод
В среднем чем больше счёт, тем больше чаевые (умеренная связь), но крупный счёт не всегда гарантирует высокие чаевые.

Гипотеза 2: на ужине чаевые выше, чем на обеде

Что сделано:

1. Создан tip_percent
2. Расчёт средних и медианных чаевых
3. Построен barplot и boxplot

```python
tips['tip_percent'] = tips['tip'] / tips['total_bill'] * 100

print('Средние и медианные чаевые:')
display(tips.groupby('time', observed=False)['tip'].agg(['mean', 'median']).round(2))

print()
print('Процент чаевых:')
display(tips.groupby('time', observed=False)['tip_percent'].agg(['mean']).round(2))

sns.barplot(data=tips, x="time", y="tip_percent")
plt.title("Средний процент чаевых (обед и ужин)")
plt.xlabel("Время посещения")
plt.ylabel("Процент чаевых")
plt.show()

sns.boxplot(data=tips, x="time", y="tip_percent")
plt.title("Разброс процента чаевых (обед и ужин)")
plt.xlabel("Время посещения")
plt.ylabel("Процент чаевых")
plt.show()
```

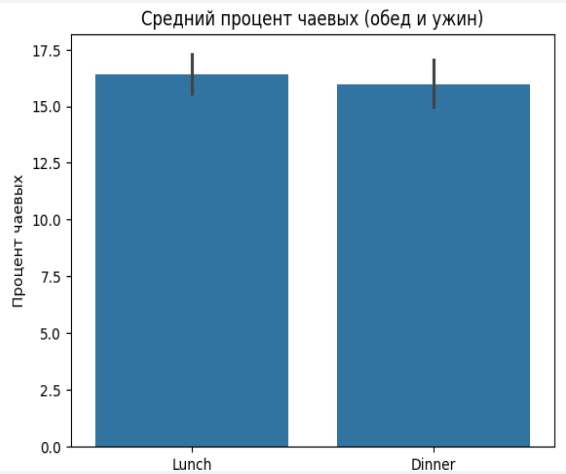
Результат

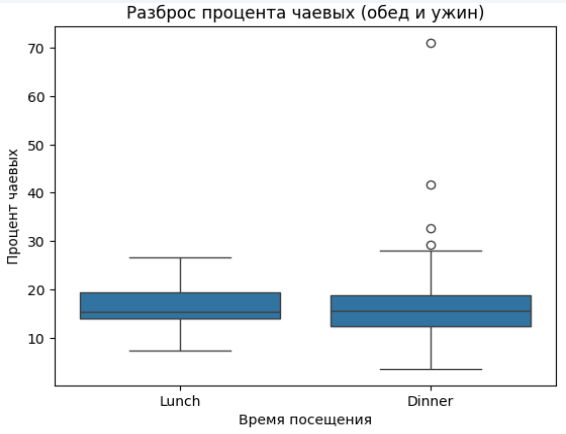
Средние и медианные чаевые:

time	mean	median
Lunch	2.73	2.25
Dinner	3.10	3.00

Процент чаевых:

time	mean
Lunch	16.41
Dinner	15.95





3.10 vs 2.73
чаевые
в деньгах

16.41 vs 15.95
чаевые
в процентах

Вывод

Гипотеза верна только для абсолютных денег. В процентах от счёта лидирует обед.

Гипотеза 3: в разные дни недели чаевые отличаются

Что сделано:

1. Рассчитать средний `tip` по `day`
2. Рассчитать средний `total_bill` по `day`
3. Рассчитать средний `tip_percent` по `day`
4. Построить barplot среднего `tip` по `day`

```
print('Средние чаевые в день:')
display(tips.groupby('day', observed=False)['tip'].agg(['mean']).round(2))

print()
print('Итоговый счёт в день:')
display(tips.groupby('day', observed=False)['total_bill'].agg(['mean']).round(2))

print()
print('Процент чаевых в день:')
display(tips.groupby('day', observed=False)['tip_percent'].agg(['mean']).round(2))

sns.barplot(data=tips, x="day", y="tip")
plt.title("Средние чаевые по дням недели")
plt.xlabel("День недели")
plt.ylabel("Средние чаевые")
plt.show()
```

Результат

Средние чаевые в день:

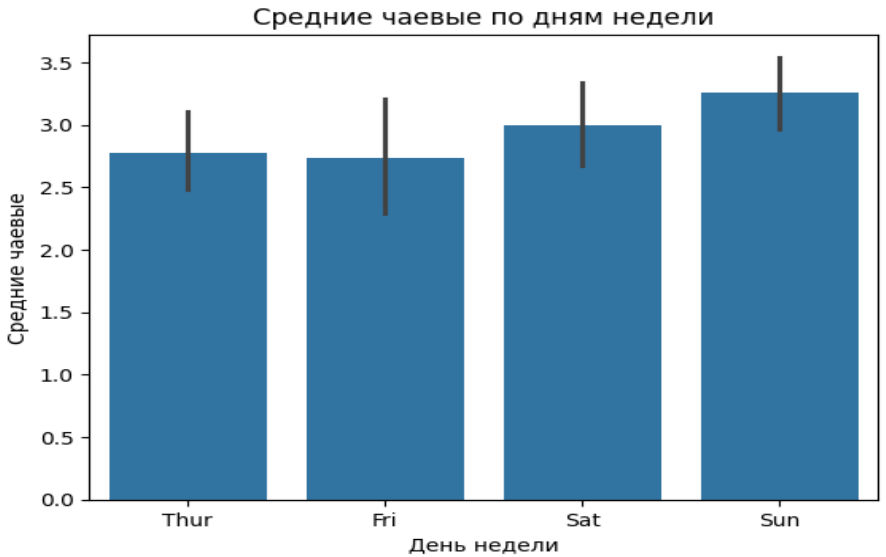
day	mean
Thur	2.77
Fri	2.73
Sat	2.99
Sun	3.26

Итоговый счёт в день:

day	mean
Thur	17.68
Fri	17.15
Sat	20.44
Sun	21.41

Процент чаевых в день:

day	mean
Thur	16.13
Fri	16.99
Sat	15.32
Sun	16.69



3.26
лидер - воскресенье

2.73
минимум - пятница

Вывод

Гипотеза подтверждается. Чаевые в разные дни недели отличаются. В выходные, где большие счета, процент чаевых не всегда самый высокий.

Гипотеза 4: размер компании влияет на счет и чаевые

Что сделано:

1. Рассчитан средний `total_bill` по `size`
2. Рассчитан средний `tip` по `size`
3. Рассчитан средний `tip_percent` по `size`
4. Построен lineplot для этих показателей.

```
print('Количество чеков по размеру компании:')
display(tips['size'].value_counts())

print('Средний счёт по размеру компании:')
display(tips.groupby('size', observed=False)['total_bill'].agg(['mean']).round(2))

print()
print('Чаевые по размеру компании:')
display(tips.groupby('size', observed=False)['tip'].agg(['mean']).round(2))

print()
print('Процент чаевых по размеру компании:')
display(tips.groupby('size', observed=False)['tip_percent'].agg(['mean']).round(2))

sns.lineplot(data=tips, x="size", y="total_bill", marker="o")
sns.lineplot(data=tips, x="size", y="tip", marker="o")
sns.lineplot(data=tips, x="size", y="tip_percent", marker="o")
plt.title("Показатели по размеру компании")
plt.xlabel("Размер компании")
plt.ylabel("Значение")
plt.legend(["Счёт", "Чаевые", "Процент"])
plt.show()

```

Результат

Количество чеков по размеру компании:

size	count
2	156
3	38
4	37
5	5
1	4
6	4

Средний счёт по размеру компании:

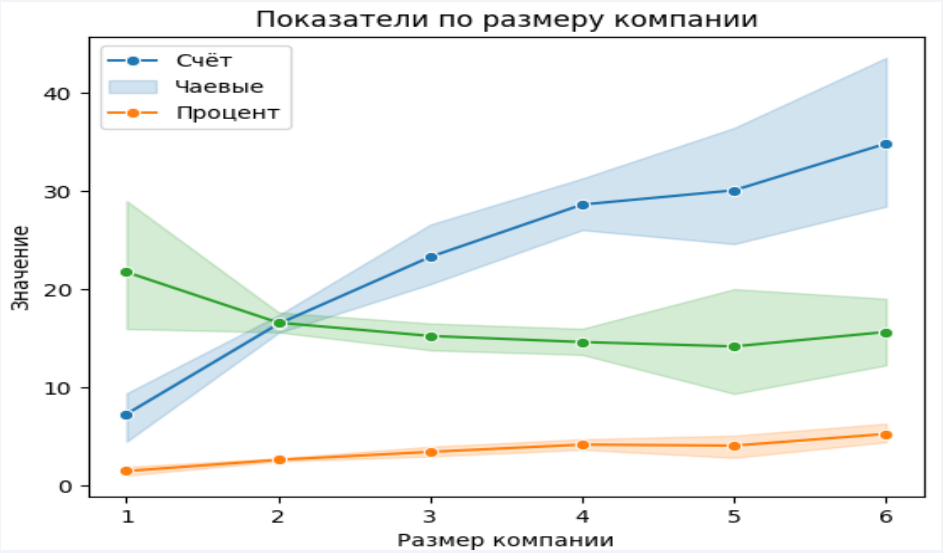
size	mean
1	7.24
2	16.45
3	23.28
4	28.61
5	30.07
6	34.83

Чаевые по размеру компании:

size	mean
1	1.44
2	2.58
3	3.39
4	4.14
5	4.03
6	5.22

Процент чаевых по размеру компании:

size	mean
1	21.73
2	16.57
3	15.22
4	14.59
5	14.15
6	15.62



Вывод

Гипотеза подтверждается. Абсолютные счёт и чаевые растут с компанией, а процент чаевых — падает.

Гипотеза 5: комбинации факторов важнее одного признака

Что сделано:

1. Создать сводную таблицу среднего `tip` по `day` и `time`
2. Создать сводную таблицу среднего `tip_percent` по `smoker` и `sex`
3. Построить heatmap для обеих таблиц

```python
print('Средние чаевые по дням недели и времени посещения:')
display(tips.pivot_table(
    index='day',
    columns='time',
    values='tip',
    aggfunc='mean',
    observed=False
).round(2))

print()
print('Средний процент чаевых по статусу курения и полу:')
display(tips.pivot_table(
    index='sex',
    columns='smoker',
    values='total_bill',
    aggfunc='mean',
    observed=False
).round(2))

pivot1 = tips.pivot_table(
    index='day',
    columns='time',
    values='tip',
    aggfunc='mean',
    observed=False
).round(2)

pivot2 = tips.pivot_table(
    index='sex',
    columns='smoker',
    values='total_bill',
    aggfunc='mean',
    observed=False
).round(2)

plt.figure(figsize=(8, 5))
sns.heatmap(pivot1, annot=True, cmap='coolwarm', fmt='.2f')
plt.title('Средние чаевые по дням и времени')
plt.xlabel('Время посещения')
plt.ylabel('День недели')
plt.show()

plt.figure(figsize=(8, 5))
sns.heatmap(pivot2, annot=True, cmap='coolwarm', fmt='.2f')
plt.title('Средний счёт по полу и курению')
plt.xlabel('Курит')
plt.ylabel('Пол')
plt.show()
```

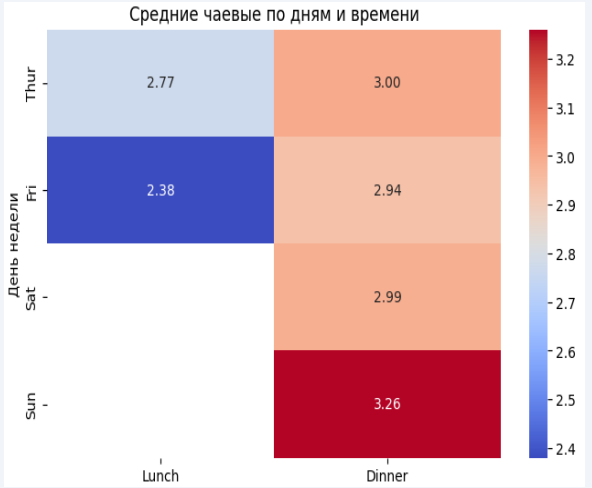
Результат

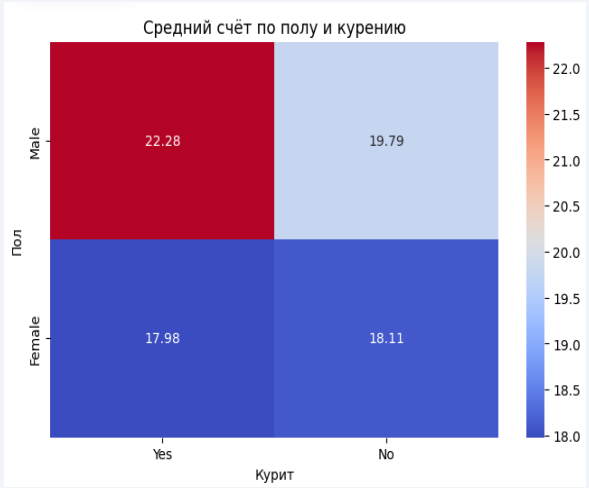
Средние чаевые по дням недели и времени посещения:

day	time Lunch	Dinner
Thur	2.77	3.00
Fri	2.38	2.94
Sat	NaN	2.99
Sun	NaN	3.26

Средний процент чаевых по статусу курения и полу:

sex	smoker Yes	No
Male	22.28	19.79
Female	17.98	18.11





Вывод

Гипотеза подтверждается, комбинации «день+время» и «пол+курение» дают больше информации, чем один признак.